

BLM308 Veri Madenciliği — Final Proje Raporu

[Telekom Müşteri Kaybı (Churn) Tahmini ve Web Arayüzü]

[FATMA NUR ATAGÜN — 231041022]

[HAYRUNNİSA KAYA — 231041047]

Bahar 2026

Table of Contents

Takım Bilgileri ve Rol Dağılımı	1
Özet (Abstract)	1
1. Giriş	2
1.1. Problem Tanımı	2
1.2. Motivasyon ve İş Değeri	2
1.3. Literatür ve İlgili Çalışmalar	3
1.4. Raporun Yapısı	3
2. Yöntem (CRISP-DM)	3
2.1. Genel Akış	3
2.2. Kullanılan Araçlar	4
3. Veri	4
3.1. Veri Kaynağı	5
3.2. Veri Tanımı	5
3.3. Keşifsel Veri Analizi (EDA)	5
3.4. Ön İşleme	7
4. Model	7
4.1. Seçilen Algoritmalar	8
4.2. Deney Kurulumu	8
4.3. Hiperparametre Ayarı	8
5. Sonuçlar ve Tartışma	9
5.1. Performans Karşılaştırması	9
5.2. Confusion Matrix	9
5.3. İstatistiksel Test (3+ kişilik takımlar)	10
5.4. Bias-Variance Yorumu	10

5.5. Model Yorumlanabilirliği (SHAP Analizi)	11
5.6. Python Karşılaştırması (yapıldıysa)	12
6. Sonuç	12
6.1. Özet	12
6.2. Kısıtlar	13
6.3. Gelecek Çalışmalar	13
6.4. Yapay Zeka Kullanım Beyanı	13
Kaynaklar	14

Takım Bilgileri ve Rol Dağılımı

Ad Soyad	Numara	Rol	Yazdığı/Yaptığı Bölümler
Fatma Nur ATAGÜN	231041022	Veri Mühendisi	Bölüm 3 (Veri), Kod: on_isleme.py, xai_analizi.py
Fatma Nur ATAGÜN	231041022	Model Mühendisi	Bölüm 4 (Model), Weka deneyleri, Python modelleri ve app.py (Streamlit Arayüzü)
Hayrunnisa KAYA	231041047	Değerlendirme	Bölüm 5 (Sonuçlar), Confusion Matrix analizi, İş Değeri ve XAI yorumlamaları
Hayrunnisa KAYA	231041047	Raporlama	Bölüm 1, 2, 6 + Genel Rapor Organizasyonu

Proje türü: 1. Uçtan uca pipeline (Kaggle Telco Customer Churn veri seti ile CRISP-DM süreçleri)

Takım büyüklüğüne göre ek kapsam (Talep Edilen Bonuslar):

- Interpretable ML / XAI (SHAP ile kararların açıklanması) (+3 Puan)
- Sektör Vaka Çalışması (Telekom sektöründe iş değeri ve Hata/Confusion Matrix analizi) (+2 Puan)
- Web Arayüzü Geliştirme (Streamlit ile uçtan uca etkileşimli panel) (Açık Uçlu Bonus)
- Projenin GitHub Reposu olarak teslim edilmesi (+5 Puan) - [\[GitHub Linki\]](#)
- Python ile Weka performans karşılaştırması (+3 Puan)

Özet (Abstract)

Bu çalışmada telekomünikasyon sektöründeki müşteri kaybı (Churn) problemi ele alınmıştır. Veri olarak 7043 müşterinin demografik, abonelik ve finansal bilgilerini içeren Telco Customer Churn veri seti kullanılmış; veri ön işleme aşamasında eksik veriler temizlenip kategorik değişkenler One-Hot Encoding yöntemiyle sayısallaştırılmıştır. Hazırlanan veri seti Weka ortamında **J48, Naive Bayes, Lojistik Regresyon ve Random Forest** yöntemleriyle modellenmiş ve Accuracy (Doğruluk), Precision, Recall ile ROC-AUC metriklerine göre değerlendirilmiştir. Sonuçlara göre en yüksek genel doğruluk oranına **%80.29 ile Lojistik Regresyon** modeli ulaşırken, sınıfları birbirinden ayırt etme gücü en yüksek olan model 0.822'lik ROC-AUC değeriyle Random Forest olmuştur. Weka analizlerinin ardından, projenin canlı dağıtımını amacıyla Python (scikit-learn) ortamında **%80.34** doğruluğa sahip bir Lojistik Regresyon modeli eğitilmiş ve Streamlit framework'ü kullanılarak anlık risk tahmini yapabilen etkileşimli bir web arayüzü (app.py) başarıyla hayata geçirilmiştir. Modelin kararları ayrıca SHAP (Açıklanabilir Yapay Zeka) analizleriyle yorumlanarak iş değeri sunulmuştur.

Anahtar kelimeler: veri madenciliği, sınıflandırma, Weka, Lojistik Regresyon, Churn Tahmini, SHAP, Streamlit

1. Giriş

1.1. Problem Tanımı

Telekomünikasyon sektörü, pazarın doygunluğa ulaşması ve yoğun rekabet koşulları nedeniyle "**müşteri kaybı**" (**churn**) problemiyle karşı karşıyadır. Mevcut bir aboneyi elde tutma maliyeti, yeni bir abone kazanma maliyetine kıyasla **5 ila 25 kat daha düşük** olduğu için, sadık müşteri tabanının korunması şirketlerin finansal sürdürülebilirliği açısından kritik bir önem taşımaktadır.

Bu çalışmada temel problem, abonelerin demografik özellikleri, sözleşme yapıları ve hizmet kullanım alışkanlıklarını analiz ederek; sistemi terk etme eğiliminde olan riskli kullanıcıların, iptal kararı almadan önce tahmin edilmesidir. Müşteri kaybı tahmini, sadece bir sınıflandırma problemi değil; aynı zamanda pazarlama bütçelerinin optimize edilmesi ve proaktif müşteri ilişkileri stratejileri geliştirilmesi için stratejik bir karar destek sürecidir. Geliştirilen model ile riskli abonelerin erkenden tanımlanması, şirketin ciro kayıplarının azaltılması ve müşteri yaşam boyu değerinin (CLV) artırılması hedeflenmektedir.

1.2. Motivasyon ve İş Değeri

Geliştirilen model; üst yönetim, pazarlama ve müşteri ilişkileri departmanlarına veri odaklı bir karar destek mekanizması sunar. Modelin sunduğu en büyük iş değeri, pazarlama bütçelerinin tüm abone kitlesi yerine sadece "yüksek riskli" olarak skorlanan segmente yönlendirilerek verimliliğin artırılmasıdır. Gerçek hayat senaryosunda sistem tarafından tespit edilen riskli abonelere, çağrı merkezleri veya dijital kanallar üzerinden

kişiselleştirilmiş sadakat teklifleri sunularak elde tutma (retention) süreçleri işletilir. Bu sayede müşteri yaşam boyu değeri (CLV) korunarak şirketin finansal sürdürülebilirliği güvence altına alınır.

1.3. Literatür ve İlgili Çalışmalar

Müşteri kaybı (churn) tahmini, veri madenciliği literatüründe şirketlerin karar destek sistemlerine entegre edilen kritik bir araştırma alanıdır. Witten vd. (2017), temel sınıflandırma modellerinin (karar ağaçları, kural tabanlı sistemler) teorik altyapısını ve Weka platformu üzerinde çapraz doğrulama ile kararlı hale getirilme süreçlerini detaylandırmıştır. Benzer şekilde Han vd. (2022), endüstriyel veri kümelerinde veri temizleme ve öznitelik seçimi gibi ön işleme adımlarının tahmin başarısı üzerindeki belirleyici etkisini ortaya koymuştur.

Telekomünikasyon sektöründe doğrusal ve ağaç tabanlı modellerin performans karşılaştırmaları literatürde yaygın bir çalışma konusudur. Vafeiadis vd. (2015), Lojistik Regresyon algoritmasının müşteri davranışlarını yakalamada yüksek genelleme yeteneğine sahip olduğunu ve aşırı öğrenme (overfitting) riskini minimize ettiğini belirtmiştir. Sınıf dengesizliği sorununa odaklanan Amin vd. (2019) ise k-NN ve Random Forest gibi algoritmaların hassasiyetini artırmak için doğru veri kodlama (encoding) stratejilerinin zorunlu olduğunu vurgulamıştır.

Güncel literatürde yüksek doğruluk oranı tek başına yeterli görülmemekte; kararların iş dünyasında yorumlanabilmesi için "Açıklanabilir Yapay Zeka (XAI)" metodolojileri öne çıkmaktadır. Lundberg ve Lee (2017) tarafından geliştirilen SHAP metodolojisi, telekomünikasyon gibi sektörlerde "kara kutu" modelleri şeffaflaştırarak pazarlama birimlerine aksiyon alınabilir çözümler sunmaktadır. Bu çalışma, söz konusu literatürdeki metodolojik standartlar ve açıklanabilirlik ilkeleri temel alınarak kurgulanmıştır.


1.4. Raporun Yapısı

Bu çalışma, akademik bütünlüğü sağlamak adına altı ana bölümden oluşmaktadır: Giriş bölümünün ardından; Bölüm 2'de projenin metodolojik çerçevesini oluşturan CRISP-DM süreçleri ve yazılım araçları tanıtılmaktadır. Bölüm 3'te Telco veri setinin yapısal tanımları, keşifsel veri analizi (EDA) bulguları ve uygulanan ön işleme adımları detaylandırılmaktadır. Bölüm 4'te seçilen sınıflandırma algoritmaları, deneysel test kurulumları ve hiperparametre optimizasyon süreçleri aktarılmaktadır. Bölüm 5'te modellerin metrik bazlı performans karşılaştırmaları, karmaşıklık matrisleri, bias-variance yorumları ve modele şeffaflık kazandıran açıklanabilir yapay zeka (XAI) analizleri sunulmaktadır. Bölüm 6'da ise elde edilen bulgular özetlenerek projenin kısıtları ve gelecek çalışma planları tartışılmaktadır.

2. Yöntem (CRISP-DM)

Projemizde, veri madenciliği süreçlerinin endüstriyel standardı olan CRISP-DM metodolojisi uygulanmıştır. Bu yöntem, problemin tanımlanmasından modelin dağıtımına kadar olan süreci yinelemeli (iterative) bir yapıda yönetmemize olanak tanımıştır.

2.1. Genel Akış



Metodolojinin proje özelindeki iş akışı şu beş ana aşamadan oluşmaktadır:

- **İş ve Veri Anlayışı:** Problemin tanımlanması ve IBM "Telco Customer Churn" veri setinin kapsamının belirlenmesi.
- **Veri Hazırlama:** Ham verinin temizlenmesi, aykırı değerlerin tespiti, normalizasyon ve kodlama (encoding) süreçleri.
- **Modelleme:** İhtiyaca yönelik **4 farklı algoritmanın (J48, Naive Bayes, Random Forest, Lojistik Regresyon)** seçimi ve optimize edilmesi.
- **Değerlendirme:** Modellerin doğruluk, Recall, F1 ve ROC-AUC metrikleri ile **Hata Analizi (Confusion Matrix)** üzerinden çapraz doğrulama ile test edilmesi.
- **Dağıtım:** Eğitilen modelin joblib ile kaydedilmesi ve Streamlit üzerinden interaktif bir web paneli olarak yayına alınması. Bu döngüsel yapı, modelin performansını sürekli olarak takip etmemizi ve gereksinimlere göre iyileştirme yapmamızı mümkün kılmıştır.

Bu döngüsel yapı, modelin performansını sürekli olarak takip etmemizi ve gereksinimlere göre iyileştirme yapmamızı mümkün kılmıştır.

2.2. Kullanılan Araçlar

- **Weka (3.8.6):** Veri madenciliği ve makine öğrenmesi algoritmalarının deneysel simülasyonları, parametre optimizasyonları ve çapraz doğrulama süreçleri için temel platform olarak kullanılmıştır.
- **Python (3.11):** Veri ön işleme (pandas, numpy), model geliştirme (scikit-learn) ve açıklanabilir yapay zeka (XAI / SHAP) analizleri için temel programlama dili olarak kullanılmıştır.
- **Arayüz ve Dağıtım:** Modelin canlı web arayüzü (app.py) için Streamlit kütüphanesi tercih edilmiş, projenin kaynak kod teslimi ve dokümantasyonu için ise **GitHub** kullanılmıştır.
- **Sistem Mimarisi:** Veri seti önce Weka üzerinde doğrulanmış, ardından elde edilen en iyi model parametreleri Python (scikit-learn) ortamına aktarılarak canlı arayüz üzerinden son kullanıcıya sunulmuştur.

Bu şekilde hem modellerimiz doğru oldu hem de yaptığımız işin adını tam koyduk.

3. Veri

3.1. Veri Kaynağı

Bu çalışmada kullanılan veri seti, telekomünikasyon sektöründeki müşteri davranışlarını analiz etmek amacıyla literatürde yaygın olarak kabul görmüş olan **IBM Telco Customer Churn** veri setidir. Söz konusu veri seti, Kaggle üzerinden temin edilmiş olup, içerisinde abonelerin demografik bilgileri, aldıkları hizmetler, sözleşme türleri ve ödeme yöntemleri gibi 7043 satır ve 21 öznitelikten oluşan güncel ve yapılandırılmış verileri barındırmaktadır.

3.2. Veri Tanımı

Tablo 1: Veri Setinin Yapısal Özellikleri

Özellik	Açıklama
Örnek sayısı	7043 Satır (Müşteri Kaydı)
Öznitelik sayısı	21 (20 Bağımsız Değişken + 1 Hedef Değişken)
Hedef değişken	Churn (Müşterinin ayrılıp ayrılmadığı: Yes / No)
Sınıf sayısı / aralığı	2 Sınıf (Kategorik / İkili Sınıflandırma)
Sınıf dengesi	No (Ayrılmayan): 5174 (%73.46) Yes (Ayrılan): 1869 (%26.54)

Veri setindeki 20 bağımsız öznitelik üç ana grupta sınıflandırılmıştır:


- Demografik Bilgiler:** gender, SeniorCitizen, Partner, Dependents.
- Hesap ve Sözleşme Bilgileri:** tenure, Contract, PaperlessBilling, PaymentMethod, MonthlyCharges, TotalCharges.
- Hizmet Bilgileri:** PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies.

3.3. Keşifsel Veri Analizi (EDA)

Keşifsel veri analizi, veri setindeki özniteliklerin dağılımını ve birbirleriyle olan etkileşimini ortaya koyarak modelin doğruluk başarısını artıracak ön işleme stratejilerini belirlemek amacıyla gerçekleştirilmiştir.


- Sınıf Dengesizliği ve Temel İstatistikler:** Weka üzerinden elde edilen ilk incelemede (bkz. Şekil 3.1), veri setinde toplam 7043 örnek bulunduğu ve hedef değişken olan Churn dağılımında belirgin bir dengesizlik olduğu görülmüştür. Ayrılmayan müşterilerin (No) toplam veri içindeki oranı %73.4 iken, ayrılanların

(Yes) oranı %26.6 seviyesindedir. Bu dengesizlik, modelleme aşamasında sınıf ağırlıklarının optimize edilmesini zorunlu kılmıştır.




Şekil 1: Hedef Değişken (Churn) Sınıf Dağılım Grafiği

2. **Çoklu Doğrusal Bağlantı (Multicollinearity) Analizi:** Sayısal öznitelikler (tenure, MonthlyCharges, TotalCharges) arasındaki ilişkiyi incelemek adına oluşturulan korelasyon matrisi (bkz. Şekil 2), değişkenler arasında güçlü bir ilişki olduğunu göstermektedir. Özellikle tenure (üyelik süresi) ve TotalCharges (toplam ödeme) arasındaki **0.83**'lük yüksek korelasyon, modelde çoklu doğrusal bağlantı riskini işaret etmektedir. Bu durumu baskılamak amacıyla Lojistik Regresyon modellerinde Ridge (L2) regularizasyon katsayıları kullanılmıştır.



Şekil 2: Sayısal Öznitelikler Arasındaki Pearson Korelasyon Isı Haritası

3. **Öznitelik Bazlı Davranış Analizi:** Veri setindeki tüm özniteliklerin dağılımını gösteren Şekil 3, özellikle Contract ve InternetService değişkenlerinin churn davranışı üzerinde ayırt edici bir güce sahip olduğunu ortaya koymaktadır. tenure değişkenindeki uç değer yoğunluğu ve ödeme yöntemlerine göre ayrılma oranlarındaki farklılıklar, proaktif müşteri elde tutma stratejileri için temel göstergeler olarak tanımlanmıştır.



Şekil 3: Telekom Veri Setindeki Tüm Bağımsız Özniteliklerin Churn Kırılımına Göre Histogram Dağılımları (Weka Explorer Görünümü)

3.4. Ön İşleme

1. Eksik değer işleme: TotalCharges özniteliğinde tespit edilen 11 adet boş kayıt, veri bütünlüğünü bozmamak adına veri setinden ayıklanmıştır.
2. Outlier tespiti: Sayısal değişkenler üzerinde gerçekleştirilen dağılım analizlerinde, verinin sektör standartları içerisinde olduğu saptanmış ve aykırı değer temizliğine ihtiyaç duyulmadığı görülmüştür.
3. Normalizasyon / standardizasyon: MonthlyCharges ve TotalCharges değişkenleri, **Lojistik Regresyon modelinde** oluşabilecek sapmaları önlemek ve katsayı optimizasyonunu hızlandırmak amacıyla Min-Max ölçeklendirme (0-1 aralığı) ile normalize edilmiştir.
4. Kodlama (one-hot, label encoding): Nominal kategorik değişkenler için **One-Hot Encoding** yöntemi kullanılmış, hedef değişken olan Churn ise **Label Encoding** (Yes=1, No=0) ile ikili sisteme dönüştürülmüştür.
5. Öznitelik seçimi: Modelin karmaşıklığını azaltmak ve gürültüyü engellemek adına, hedef değişkenle anlamlı bir ilişkisi bulunmayan customerID gibi kimlik bilgisi içeren sütunlar setten çıkarılmıştır.
6. Dengesizlik tedavisi (SMOTE, class-weight): Veri setindeki %73-26'lık sınıf dağılımı dengesizliğini yönetmek amacıyla, yapay veri üretmek yerine **Cost-Sensitive Learning (Ağırlıklandırma)** metodu tercih edilmiş ve modelin azınlık sınıfı (Churn=Yes) üzerindeki hassasiyeti artırılmıştır.

4. Model

4.1. Seçilen Algoritmalar

Bu çalışmada, müşteri kaybı tahmini probleminin karmaşık yapısını (doğrusal olmayan ilişkiler, dengesiz sınıf dağılımı ve farklı veri tipleri) kapsamlı bir şekilde ele almak amacıyla dört farklı makine öğrenmesi yaklaşımı seçilmiştir. Algoritmalar; tahmin başarısı, modelin yorumlanabilirliği ve veri setindeki davranışları yakalama yetenekleri göz önüne alınarak belirlenmiştir.

Tablo 2: Deneylerde Kullanılan Algoritmaların Yapısal Özellikleri ve Weka Sınıf Tanımları

Model	Tür	Weka Sınıf Adı	Notlar
J48	Karar Ağacı	trees.J48	minNumObj=2 (Budama ile aşırı öğrenmeyi önlemek için optimize edildi).
Naive Bayes	Olasılıksal	bayes.NaiveBayes	Özniteliklerin bağımsız olduğu varsayımıyla çalışan, veri dağılımını hızlı ölçen temel (baseline) model.
Random Forest	Ensemble	trees.RandomForest	numTrees=100 (Varyansı düşürmek, sınıf dengesizliğine karşı model kararlılığını artırmak için).
Logistic	Doğrusal Model	functions.Logistic	Ridge penaltısı (1.0E-8) ile optimize edilmiştir; performansıya öne çıkan şampiyon/ana modelimizdir .

4.2. Deney Kurulumu

- Değerlendirme protokolü:** Veri setindeki sınıf dengesizliği dikkate alınarak, her katmanda (fold) sınıfların oransal dağılımını koruyan 10-Fold Stratified Cross-Validation yöntemi tercih edilmiştir. Bu protokol, model performansının veri üzerindeki rastlantısallıktan bağımsız olduğunu garantiler.
- Train/Test bölümü (varsa):** Modelin performansını dışsal bir veri kümesi üzerinde valide etmek adına, veri seti başlangıçta %70 eğitim (train) ve %30 test olacak şekilde ayrılmıştır.
- Hiperparametre ayarı:** Modellerin optimize edilmesi sürecinde, algoritmaların doğasına uygun olarak Grid Search mantığı kullanılmıştır. Deneyimsel denemeler sonucunda, modelin en yüksek metrik değerlerine ulaştığı manuel parametre değerleri (örn: J48 için budama seviyeleri, RandomForest için ağaç sayısı) sabitlenmiştir.
- Tekrar sayısı:** Modelin kararlılığını test etmek amacıyla deneyler farklı random seed değerleriyle tekrarlanmış ve ortalamalar baz alınmıştır. Bu sayede başlangıç ağırlıklarının model başarısı üzerindeki etkisi izole edilmiştir.

4.3. Hiperparametre Ayarı

Model	Hiperparametre	Denenen Değerler	Seçilen Değer
J48	minNumObj	2, 5, 10, 20	2
Naive Bayes	useKernelEstimator	True, False	False
RandomForest	numIterations	50, 100, 200	100
Logistic	ridge	1.0E-9, 1.0E-8, 1.0E-7	1.0E-8

Analiz ve Gerekçelendirme

- **J48 (Karar Ağacı):** Yaprak düğümündeki minimum örnek sayısı (minNumObj) olarak 2 seçilmesi, ağacın verideki detaylı örüntüleri yakalamasına olanak sağlamış, ancak arka plandaki budama (pruning) ile aşırı öğrenmenin önüne geçilmiştir.
- **Naive Bayes:** useKernelEstimator parametresi False olarak bırakılmış, veri setindeki sayısal değişkenlerin standart dağılım varsayımıyla işlenmesinin tahmin hızını ve temel doğruluğu koruduğu saptanmıştır.
- **Random Forest:** numIterations (ağaç sayısı) değeri, modelin hesaplama maliyeti ile tahmin gücü arasındaki optimum denge noktası olan 100 olarak belirlenmiştir.
- **Logistic Regression:** Ridge parametresi, modelin katsayılarını kısıtlayarak (regularization) Bölüm 3.3'te tespit edilen tenure ve TotalCharges arasındaki çoklu doğrusal bağlantı (multicollinearity) etkisini minimize etmek adına 1.0E-8 olarak optimize edilmiştir.

5. Sonuçlar ve Tartışma

5.1. Performans Karşılaştırması

Tablo 3: Eğitilen Modellerin Performans Metriklerinin Karşılaştırılması

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
J48	%77.99	0.769	0.780	0.772	0.758
Naive Bayes	%72.05	0.741	0.720	0.728	0.801
Random Forest	%78.78	0.776	0.788	0.779	0.822
Lojistik Regresyon	%80.29	0.798	0.803	0.796	0.841

5.2. Confusion Matrix

Modellerimizin tahmin performansını detaylandırmak ve hangi sınıfta (Churn=Yes/No) daha çok hata yapıldığını gözlemlemek amacıyla, şampiyon modelimiz olan **Lojistik Regresyon** için karmaşıklık matrisi analiz edilmiştir.

Tablo 4: Lojistik Regresyon Karmaşıklık Matrisi Özeti

TN (Doğru Kalacak)	FP (Yanlış Ayrılacak / Tip 1 Hata)	FN (Kaçırılan Churn / Tip 2 Hata)	TP (Doğru Yakalanan Churn)
4631	543	845	1024

Matris Analizi ve İş Değeri Yorumu:

Lojistik Regresyon modelinin hata dağılımı incelendiğinde iş değeri perspektifinden stratejik bir sonuç ortaya çıkmaktadır:

- **Tip 1 Hata (False Positive - 543 müşteri):** Modelin ayrılacak sanıp yanlışlığı bu grupta şirket, aslında sistemde kalacak olan müşterilere gereksiz promosyon/indirim sunarak pazarlama bütçesi israfı yaşayacaktır.
- **Tip 2 Hata (False Negative - 845 müşteri):** Modelin "sistemde kalacak" diyerek güvenli olarak etiketlediği ancak gerçekte rakiplere giden bu grup, telekom şirketi için en büyük finansal zarardır.

Sonuç: Telekomünikasyon sektöründe yeni bir müşteri kazanma maliyeti, eldeki müşteriyi tutmaktan çok daha pahalıdır. Bu nedenle 845 müşterinin tamamen kaybedilmesi (Tip 2 hata), 543 müşteriye fazladan indirim yapılmasından (Tip 1 hata) çok daha tehlikelidir. Modelin karar eşiği (threshold) düşürülerek, False Negative oranının minimize edilmesi hedeflenmelidir.

5.3. İstatistiksel Test (3+ kişilik takımlar)

(Paired t-test veya McNemar testi sonuçları. p-değerleri, anlamlı fark var mı?)

5.4. Bias-Variance Yorumu


Modelleme sürecimizin sonunda, algoritmaların genelleme yeteneklerini Bias-Variance dengesi üzerinden değerlendirdik:

- **J48 ve Random Forest:** Yapısal olarak çok dallanan ve yüksek varyans (variance) üretmeye meyilli modellerdir. Ancak J48'de budama (pruning) ve Random Forest'ta 100 ağaçlık ensemble mimarisi kullanılarak overfitting (ezberleme) engellenmiş, varyans kontrol altına alınmıştır.

- **Naive Bayes:** Öznitelikler arası bağımsızlık varsayımı (high bias) nedeniyle model, verideki karmaşık ilişkileri yakalamada yetersiz kalmış ve %72 doğrulukta kalarak underfitting eğilimi göstermiştir.
- **Lojistik Regresyon:** Veri setinin doğrusal ayrılabilir yapısına en uygun model olmuştur. Ne Random Forest kadar karmaşıklılaşp ezberleşmiş (düşük varyans) ne de Naive Bayes kadar basit kalmıştır. En optimum Bias-Variance dengesini kurarak %80.29 başarıya ulaşmıştır.

5.5. Model Yorumlanabilirliği (SHAP Analizi)

Canlı web arayüzümüzde "kara kutu" (black box) mimarisi yerine kararların arkasındaki nedenleri sunan Açıklanabilir Yapay Zeka (XAI) felsefesi benimsenmiştir. Bu doğrultuda, Lojistik Regresyon modelimizin kararları SHAP (SHapley Additive exPlanations) yöntemiyle analiz edilmiştir.



Şekil 5: SHAP Özet Grafiği ve Churn Kararını Etkileyen Faktörler

- **Müşteri Sadakati (Tenure):** Grafikteki en baskın özniteliktir. Sisteme yeni katılan müşterilerin (düşük tenure) ayrılma riskinin en yüksek seviyede olduğu görülmüştür.

- **Sözleşme Türü (Contract_Two year):** İki yıllık uzun dönem sözleşmesi olan müşterilerin churn riski keskin bir şekilde negatife (kalma eğilimine) düşmektedir.
- **Altyapı (InternetService_Fiber optic):** Fiber optik kullanan müşterilerin ayrılma eğiliminin yüksek çıkması, altyapısal bir kalite sorununa işaret etmektedir.

Telekom Müşteri Kayıp (Churn) Tahmin Sistemi

Bu panel, Telco veri seti üzerinde eğitilmiş Lojistik Regresyon modeli ile çalışmaktadır. Müşterinin sistemden çıkma (churn) riskini hesaplar.

Müşteri Bilgilerini Giriniz

Müşteri kayıp ya da sistemden çıkma (Yeni Müşteri)

12

Aylık Fatura Tutarı (\$)

50.00

Toplam Harcama (\$)

600.00

Risk Hesapla

GÜVENLİ: Müşterinin sistemde kalma ihtimali yüksek. (Risk Oranı: %30.7)

Şekil 6: Geliştirilen Canlı Web Arayüzü (app.py) Üzerinden Müşteri Risk Tahmin Ekranı

5.6. Python Karşılaştırması (yapıldıysa)

Projemizin canlı web arayüzü (app.py), Python ortamında scikit-learn kütüphanesi kullanılarak geliştirilmiştir. Canlıda çalışan Python tabanlı Lojistik Regresyon modelimiz ile Weka'daki ana simülasyon sonuçlarımızın kıyaslaması şu şekildedir:

- **Weka Sonucu:** %80.29 Doğruluk
- **Python Sonucu:** %80.34 Doğruluk İki farklı geliştirme ortamında elde edilen sonuçlar birbirine son derece paraleldir. Analiz ve algoritma seçimi aşamasında sağladığı pratiklik nedeniyle Weka tercih edilirken; modelin son kullanıcıya Streamlit framework'ü ile etkileşimli bir web paneli üzerinden anlık tahmin üretecek şekilde dağıtılması (deployment) için Python ekosistemi tercih edilmiştir.

6. Sonuç

6.1. Özet

Bu projede, telekomünikasyon sektöründeki müşteri kaybını (Churn) önceden tahmin edebilmek amacıyla veri madenciliği yöntemleri kullanılarak uçtan uca bir sistem geliştirilmiştir. İlk olarak Telco Churn veri seti eksik verilerden temizlenmiş; kategorik öznitelikler One-Hot Encoding ile sayısal hale getirilerek analize hazır edilmiştir. Weka ortamında yapılan 10-katlı katmanlı çapraz doğrulama testlerinde **J48, Naive Bayes,**

Random Forest ve Lojistik Regresyon algoritmaları kořturulmuř; en yksek genel doęruluęa **%80.29 ile Lojistik Regresyon** ulařırken, sınıfları birbirinden ayırt etme gcn 0.841 ROC-AUC deęeriyle yine Lojistik Regresyon modeli gstermiřtir. Elde edilen bu analiz bulgularından yola ıkılarak, Python (scikit-learn) ortamında **%80.34** doęruluęa sahip kararlı bir Lojistik Regresyon modeli eęitilmiř ve bu model Streamlit framework' ile alıřan canlı, etkileřimli bir web arayzne (app.py) dnřtrlmřtir. Sonu olarak, sisteme yeni girilen mřteri verilerine gre anlık risk analizi yapabilen ve SHAP analizi ile hangi faktrlerin Churn riskini artırdıęını řeffafa aıklayabilen bařarılı bir karar destek mekanizması kurulmuřtur.

6.2. Kısıtlar

Projemizin geliřtirme, eęitim ve test srelerinde karřılařtıęımız temel kısıtlar ve projenin sınırlılıkları řu řekildedir:

- **Veri Boyutu ve Sınıf Dengesizlięi:** Kullandıęımız Telco Churn veri seti (7032 satır) model eęitimi iin yeterli grnse de, sınıflar arasındaki %73 - %26'lık dengesizlik modellerimizin azınlık sınıfını (Churn) ęrenmesini zorlařtıran yapısal bir kısıt oluřturmuřtur.
- **Hesaplama Kaynaęı Sınırları:** Tm simlasyon ve testleri kendi kiřisel bilgisayarlarımız zerinde, yerel kaynaklarla yrttk. Bu durum, Random Forest gibi oklu aęa yapısıyla alıřan karmařık modellerin eęitim srelerini artırmıřtır. Daha byk veri setleri iin donanımımızın sınırdaki kalacaęı saptanmıřtır.
- **Zaman Kısıtı:** Akademik dnem devi teslim takvimine baęlı kaldıęımız iin hiperparametre optimizasyon srelerini belirli limitler dahilinde tutmak zorunda kaldık.
- **Veri eřitlilięi Eksiklięi:** Mřterilerin aęrı merkezi řikayet gemiřleri, ses analizi kayıtları veya mřteri memnuniyet anketleri (NPS skorları) gibi davranıřsal veriler kmede bulunmadıęı iin modelimizin tahmin gc sektrel veri kısıtlarına takılmıřtır.

6.3. Gelecek alıřmalar

Projenin ilerleyen ařamalarında tahmin bařarısını ve sistemin leklenebilirlięini artırmak adına, veri setindeki sınıf dengesizlięini SMOTE gibi sentetik veri artırma teknikleriyle gidermeyi planlıyoruz. Teknik derinlięi artırmak amacıyla, mevcut modellerimize ek olarak endstride yksek performans sunan XGBoost, LightGBM ve ok Katmanlı Algılayıcı (MLP) gibi derin ęrenme mimarilerini sisteme dahil etmeyi hedefliyoruz. Canlı daęıtım tarafında ise; lokalde bařarıyla alıřan Streamlit arayzn AWS veya Google Cloud gibi bulut servislerine tařıyarak kurumsal sistemlere entegre edilebilir gerek zamanlı bir API'ye dnřtrmeyi amalıyoruz. Son olarak, proje kapsamında statik olarak rettięimiz SHAP grafiklerini, web arayzne dinamik olarak entegre ederek son kullanıcıya her tahmin iin anlık grsel risk raporları sunmayı hedeflemekteyiz.

6.4. Yapay Zeka Kullanım Beyanı

Bu projenin teknik geliştirme ve dokümantasyon süreçlerinde, akademik dürüstlük ilkelerine bağlı kalınarak üretken yapay zeka (LLM) araçlarından bir "geliştirici asistanı" olarak destek alınmıştır. Projenin ana iskeletini oluşturan CRISP-DM süreçleri, Weka simülasyonları, algoritma seçimleri ve İş Değeri (Business Value) yorumlamaları tamamen takım üyelerinin entelektüel katkısıyla gerçekleştirilmiştir. Yapay zeka araçları ise yalnızca; Python ve Streamlit kodlarının hata ayıklanması (debugging), kütüphane sürüm çakışmalarının çözülmesi (NumPy/Pandas uyumsuzlukları) ve raporun dil/şablon düzenlemeleri gibi teknik ve yapısal destek amaçlı kullanılmıştır.

Kaynaklar

1. **Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2017).** *Data Mining: Practical Machine Learning Tools and Techniques*. Morgan Kaufmann. (Weka simülasyonları ve kural/ağaç algoritmalarının parametre yönetimi için).
 2. **Han, J., Kamber, M., & Pei, J. (2022).** *Data Mining: Concepts and Techniques*. Morgan Kaufmann. (Veri ön işleme, veri dönüştürme felsefesi ve k-NN modelindeki boyutun laneti teorisi için).
 3. **Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011).** Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830. (Canlı web arayüzünde kullanılan Lojistik Regresyon altyapısı için makale referansı).
 4. **IBM Watson Analytics. (2018).** *Telco Customer Churn Dataset*. Kaggle Repository. [Çevrimiçi]. Erişim Adresi: <https://www.kaggle.com/datasets/blastchar/telco-customer-churn> (Projede modellenen orijinal veri seti referansı).
 5. **Ribeiro, M. T., Singh, S., & Guestrin, C. (2016).** "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135-1144. (Arayüzdeki model kararlarını şeffaflaştıran SHAP/LIME tabanlı XAI felsefesi için makale referansı).
 6. **Streamlit Developers. (2020).** *Streamlit Framework Documentation for Machine Learning Deployment*. [Çevrimiçi]. Erişim Adresi: <https://docs.streamlit.io> (app.py canlı web arayüz mimarisi için framework referansı).
-